



SVM 算法

1、线性模型

定义：可用一条线性直线，将数据集分开的模型，称之为线性模型。



从上图看出，显然 2 号线划分得最好。那如何定义 2 号线呢？



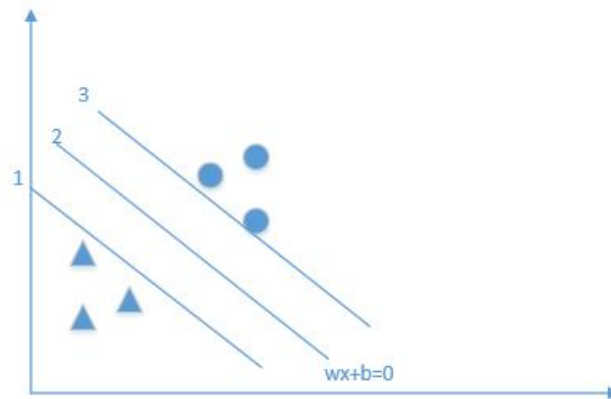
2 号线在 1、3 号线的中间，很自然， d 越大，所找线越优。

d : 间隔 margin

中间 2 号线：决策边界

引来的问题是：如何寻找最大化间隔 d ？

2、决策边界概述



$w\mathbf{x}+b > 0$, 规定在 2 号线上方, 属于+1 类;
 $w\mathbf{x}+b < 0$, 规定在 2 号线下方, 属于-1 类;

SVM 有 3 种分类:


- ◆ 数据线性可分: 硬间隔 SVM
- ◆ 数据近似线性可分: 软间隔 SVM
- ◆ 数据不可线性分: 核技巧

3、线性可分 SVM

最优化问题导出: 最大化间隔 d

- 1) 二维数据: 寻找一条直线 $w\mathbf{x}+b=0$, 可将数据切分开;
- 2) 三维空间: 寻找平面: $a\mathbf{x}+b\mathbf{y}+c=0$, 可将数据切分开;
- 3) 高维空间: 寻找超平面;

以二维数据为例:



直线 2: $wx+b=0$ ②

因为 1、3 号线是 2 平移得到的, 所以:

1 号线: $wx+b=k$ ①

3 号线: $wx+b=-k$ ③

此时, 对①③做简单处理, 两边除以 k :

$$\begin{cases} \frac{w}{k}x + \frac{b}{k} = 1 \\ \frac{w}{k}x + \frac{b}{k} = -1 \end{cases} \quad \text{II}$$

对②, 两边乘以 $\frac{1}{k}$

$$\frac{w}{k}x + \frac{b}{k} = 0$$

令 $\frac{w}{k} = w^{new}$, $\frac{b}{k} = b^{new}$, 带入 II 中


$$w^{new}x + b^{new} = 1 \quad \text{①}$$

$$w^{new}x + b^{new} = -1 \quad \text{③}$$

$$w^{new}x + b^{new} = 0 \quad \text{②}$$

综合上述所得, 可以写成:

$$\begin{cases} wx + b = 1 \\ wx + b = -1 \\ wx + b = 0 \end{cases}$$



$$\begin{cases} wx_1 + b = 1 \\ wx_2 + b = -1 \end{cases}$$

两式相减：

$$w(x_1 - x_2) = 2$$

$$\|w\| \cdot \|x_1 - x_2\| \cdot \cos\theta = 2$$

又因为由上图得出：

$$\cos\theta = \frac{d}{\|x_1 - x_2\|}$$

所以得：

$$\|w\| \cdot d = 2$$

$$d = \frac{2}{\|w\|}$$

因为要求 d 最大，所以 $\|w\|$ 要最小

$$\max_d \iff \min \frac{1}{2} \|w\|^2$$

因此问题转化：最大间隔 $d \iff$ 最小化 $\frac{1}{2} \|w\|^2$

又因为：

$$wx + b \geq 1 \quad +1 \text{ 类} \quad y = +1$$

$$wx + b \leq -1 \quad -1 \text{ 类} \quad y = -1$$

$$\implies y_i(wx + b) \geq 1$$

所以 SVM 的最优化问题：

$$\begin{cases} \min \frac{1}{2} \|w\|^2 \\ s.t. \quad y_i(wx + b) \geq 1 \end{cases}$$

3.1 SVM 算法最优化问题求解

SVM 优化问题求解：

$$\begin{cases} \min \frac{1}{2} \|w\|^2 \\ s.t. \quad y_i(wx + b) \geq 1 \end{cases}$$

在带有约束条件的问题，要求解该问题的最优解，一般采用的是拉格朗日乘数法：

举个简单例子：求 $\mu = xy + 2yz$ ，在条件 $x^2 + y^2 + z^2 = 10$ 下的极值

1) 构建拉格朗日函数：

$$L(x, y, z, \partial) = xy + 2yz + \partial(x^2 + y^2 + z^2 - 10)$$

2) 求解

$$L_x' = y + 2\partial x = 0$$

$$L_y' = x + 2z + 2\partial y = 0$$

$$L_z' = 2y + 2\partial z = 0$$

$$L_{\partial}' = x^2 + y^2 + z^2 - 10 = 0$$

$$\text{求解得： } \mu_{\max} = 5\sqrt{5}, \mu_{\min} = -5\sqrt{5}$$

对 SVM 优化问题求解：

$$\begin{aligned} L(w, \partial) &= \frac{1}{2} \|w\|^2 + \sum_{i=1}^n \partial_i [1 - y_i(wx + b)] \\ &= \frac{1}{2} \|w\|^2 + \sum_{i=1}^n \partial_i - \sum_{i=1}^n \partial_i y_i (wx + b) \\ \frac{\partial L}{\partial w} &= w - \sum_{i=1}^n \partial_i (y_i x_i) = 0 \\ \frac{\partial L}{\partial b} &= -\sum_{i=1}^n \partial_i y_i = 0 \end{aligned}$$

3.2 补充一个知识点（原问题与对偶问题）

假如原问题：

$$\begin{aligned} &\min f(w) \\ &s.t. \begin{cases} g_i(w) \leq 0 \\ h_i(w) = 0 \end{cases} \end{aligned}$$

则原问题的拉格朗日函数：

$$\begin{aligned} L(w, \partial, \beta) &= f(w) + \sum_{i=1}^n \partial_i g_i(w) + \sum_{i=1}^n \beta_i h_i(w) \\ &= f(w) + \partial^T g(w) + \beta^T h(w) \end{aligned}$$

对偶问题：

$$\theta(\partial, \beta) = \inf L(w, \partial, \beta)$$

意思就是：

- 1) 先以 w 为参数，求 $L(w, \partial, \beta)$ 的最小值
- 2) 再以 ∂, β 为参数，求 $L(w, \partial, \beta)$ 的最大值

KKT 条件：

$$\begin{cases} \partial_i, \beta_i > 0 \\ g(w) \leq 0 \\ h(w) = 0 \end{cases}$$

在满足 KKT 条件后，我们则可以将原始的最优化问题转换成求对偶函数的最优化问题；

3.3 求解 SVM 最优化问题

$$\begin{aligned} L(w, \partial) &= \frac{1}{2} \|w\|^2 + \sum_{i=1}^n \partial_i [1 - y_i(wx + b)] \\ &= \frac{1}{2} \|w\|^2 + \sum_{i=1}^n \partial_i - \sum_{i=1}^n \partial_i y_i (wx + b) \\ \frac{\partial L}{\partial w} &= w - \sum_{i=1}^n \partial_i (y_i x_i) = 0 \\ \frac{\partial L}{\partial b} &= - \sum_{i=1}^n \partial_i y_i = 0 \end{aligned}$$

所以得：

$$\begin{aligned} w &= \sum_{i=1}^n \partial_i (y_i x_i) \\ \sum_{i=1}^n \partial_i y_i &= 0 \end{aligned} \quad \text{III}$$

将其带回拉格朗日函数中得：

先以 w 为参数，求最小值：

$$\begin{aligned}
L(w, b, \partial)_{\min} &= \frac{1}{2} \|w\|^2 + \sum_{i=1}^n \partial_i [1 - y_i(wx + b)] \\
&= \frac{1}{2} \|w\|^2 + \sum_{i=1}^n \partial_i - \sum_{i=1}^n \partial_i y_i (wx + b) \\
&= \frac{1}{2} \left[\sum_{i=1}^n \partial_i (y_i x_i) \right]^2 + \sum_{i=1}^n \partial_i - \sum_{i=1}^n \partial_i y_i \left[\left(\sum_{i=1}^n \partial_i y_i x_i \right) x_j + b \right] \\
&= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \partial_i \partial_j y_i y_j x_i x_j + \sum_{i=1}^n \partial_i - \sum_{i=1}^n \sum_{j=1}^n \partial_i \partial_j y_i y_j x_i x_j - \sum_{i=1}^n \partial_i y_i b \\
&= -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \partial_i \partial_j y_i y_j x_i x_j + \sum_{i=1}^n \partial_i
\end{aligned}$$

先以 ∂ 为参数，求最大值：

$$\max \left[-\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \partial_i \partial_j y_i y_j x_i x_j + \sum_{i=1}^n \partial_i \right]$$

等价于求：

$$\min \left[\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \partial_i \partial_j y_i y_j x_i x_j - \sum_{i=1}^n \partial_i \right]$$

最后通过 SMO 算法求解得：

$$\partial^* = (\partial_1^*, \partial_2^*, \partial_3^*, \dots, \partial_k^*)$$

所以，又由III式可知，求得 w ：

$$w^* = \sum_{i=1}^n \partial_i^* (y_i x_i)$$

又因为对 SVM 的 KKT 条件是：

$$\begin{cases}
1 - y_i(wx + b) = 0 \text{ 或 } \partial_i^* = 0 \\
\frac{\partial L}{\partial w} = w - \sum_{i=1}^n \partial_i (y_i x_i) = 0 \\
\frac{\partial L}{\partial b} = \sum_{i=1}^n \partial_i y_i = 0
\end{cases}$$

所以由 $y_i(wx_i + b) - 1 = 0$ ，两边乘以 y_i ，所以得 $y_i^2(wx_i + b) - y_i = 0$

又因为 y_i 是 +1，或 -1，所以 $y_i^2 = 1$

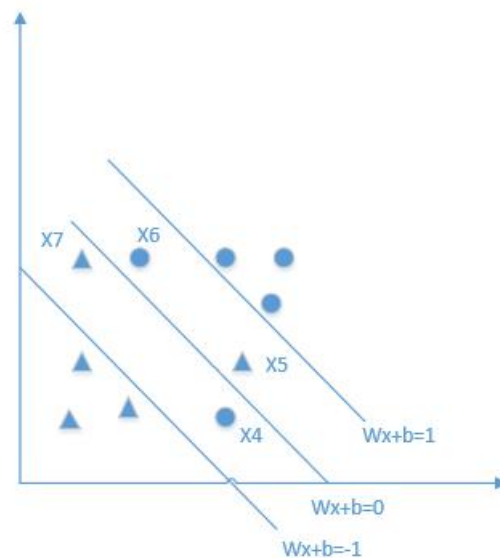
所以: $w x_i + b - y_i = 0$

所以得: $b^* = y_i - w^* x_i$, 再将 w^* 带入求得:

$$b^* = y_i - \sum_{i=1}^n \partial_i^* y_i x_i x_j$$

4、近似线性可分: 最大软间隔

近似线性可分: 在线性可分的情况下, 加入一些噪声数据点, 噪声数据点满足的约束条件是: $0 < y_i(w x + b) < 1$



噪声点: X6, X7

$$\begin{aligned} 0 < w x_6 + b < 1 & \quad y = +1 \\ -1 < w x_7 + b < 0 & \quad y = -1 \end{aligned}$$

错误点: X4, X5

总结:

正确分类的点满足:

$$y_i(w x + b) \geq 1$$

错误分类的点满足:

$$y_i(w x + b) \leq 0$$

因此对于正确分类的点：

$$y_i(wx + b) \geq 1 - \varepsilon_i \quad \varepsilon_i \text{是松弛因子}$$

希望 ε_i 越小越好；

- ◆ 当 $\varepsilon_i = 0$ 时， $y_i(wx_i + b) \geq 1$
- ◆ 当 $0 < \varepsilon_i < 1$ 时， $y_i(wx_i + b) \geq 1 - \varepsilon_i$ ，则此时存在噪声点；
- ◆ 当 $\varepsilon_i > 1$ 时， $y_i(wx_i + b) \geq 1 - \varepsilon_i$ ，则此时存在错误分类的点；

SVM 的最优化问题：

$$\begin{cases} \min \frac{1}{2} \|w\|^2 + C \cdot \sum_{i=1}^n \varepsilon_i \\ s.t. \begin{cases} y_i(wx_i + b) \geq 1 - \varepsilon_i \\ \varepsilon_i \geq 0 \end{cases} \end{cases}$$

- ◆ $C \uparrow$ ， $\varepsilon_i \downarrow$ ，即噪声少，超平面向内侧相互移动，减少间隔距离，从而减少噪声，此时，支持向量减少；
- ◆ $C \downarrow$ ， $\varepsilon_i \uparrow$ ，即噪声多，超平面向外侧相互移动，增加间隔距离，从而增加噪声，此时，支持向量增多；

5、数据不可线性分(非线性 SVM-核技巧)

核技巧：低维非线性 \Rightarrow 映射到高维空间中，即可实现线性分离；

常见的核函数：

- 1) 线性核函数： $k(x_i, x_j) = x_i \cdot x_j$
- 2) 多项式核函数： $k(x_i, x_j) = (\gamma(x_i \cdot x_j) + \gamma)^p$
- 3) 高斯核函数： $k(x_i, x_j) = e^{-\gamma(|x_i - x_j|)^2}$
- 4) Sigmoid 核函数： $k(x_i, x_j) = \tanh[\gamma(x_i - x_j) + \gamma]$